Práctica 2: Visualización y análisis de datos con Power BI

OBJETIVOS

- Conectar una herramienta de BI (Power BI) a un data lake, leyendo la capa gold.
- Entender y montar un modelo en estrella en Power BI (tabla de hechos + dimensiones) y sus relaciones.
- Crear visualizaciones efectivas (tarjetas, línea, barras, dispersión, histograma) sobre datos reales del IBEX-35.
- Introducir medidas y columnas calculadas con DAX.
- Analizar visualmente hipótesis de mercado (efecto viernes, sentimiento vs retorno, gaps) y documentar los hallazgos en un informe.

CONTEXTO

En la Práctica 1 se prepararon los datos de la aplicación (bronze → silver → gold) y se dejó la capa gold exportada a Parquet siguiendo un modelo en estrella (una tabla de hechos y tabla de dimensiones). En el patrón MVC que seguimos en todo el curso, Power BI no toca la lógica ni el dato crudo, solamente consume la gold.

PREPARACIÓN DEL ENTORNO

Power BI Desktop es gratuito y se ejecuta en Windows. Se instala desde la Microsoft Store (buscando "Power BI Desktop") o desde la web oficial de Microsoft. No necesita cuenta de pago y todo el trabajo de esta práctica es local. Una vez instalado, se abre y **se parte de un informe en blanco**.

Funcion coalesce

Spark reparte un DataFrame en particiones y, al escribir en Parquet, genera un fichero part-*.parquet por cada partición (Práctica 1). Por eso una carpeta exportada suele contener varios part-*.

Con la función coalesce(n) reduce el número de particiones a n. En particular, coalesce(1) lo deja todo en una sola partición, de modo que al escribir se obtiene un único fichero .parquet:

```
leer_delta(spark,
GOLD_HECHOS).coalesce(1).write.mode("overwrite").parquet(EXPORT_HECHOS)
 leer_delta(spark,
GOLD_DIM).coalesce(1).write.mode("overwrite").parquet(EXPORT_DIM)
```

Almacenar así los datos permite a Power BI lee la gold de forma más limpia, con un solo .parquet por tabla hay un único fichero que combinar.

Coalesce(1) concentra todos los datos en una sola partición (un solo nodo). Para volúmenes enormes podría ser un cuello de botella de memoria; para una gold de tamaño moderado es válido. En la última práctica se detallará otra forma de cargar los datos.

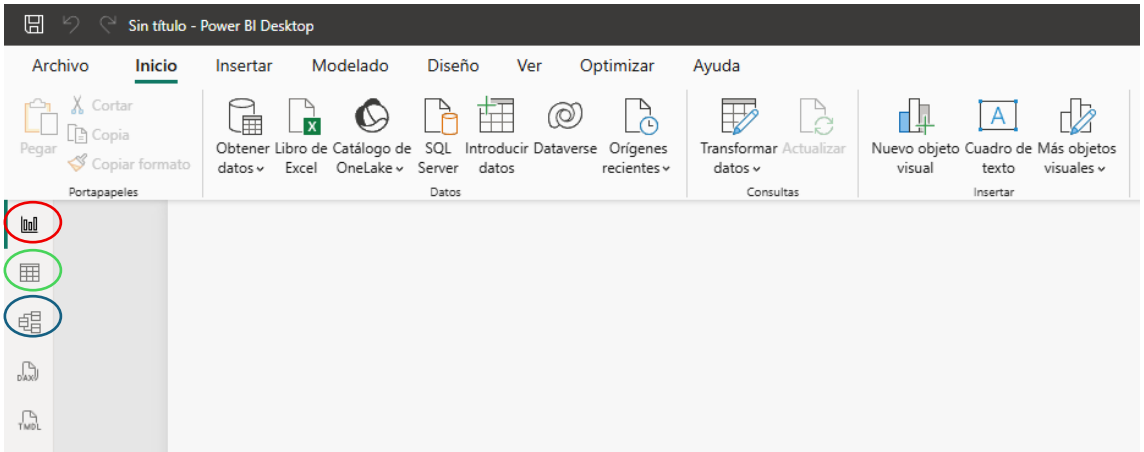
FUNCIONAMIENTO DE POWER BI

Power BI es una herramienta de inteligencia de negocio (BI) de Microsoft para explorar datos y construir cuadros de mando (dashboards) interactivos. En una arquitectura de datos ocupa la capa de servicio, es decir, la que toma los datos ya procesados y los pone delante de quien decide, a través de dashboards, aplicaciones y cuadernos. Un dashboard es, en esencia, una colección de gráficos construidos a partir de los datos, y puede actualizarse de forma programada o manual.

Se trabaja "point-and-click", es decir, arrastrando campos y eligiendo visuales, sin escribir código. Incorpora un lenguaje de fórmulas, DAX, para los cálculos (medidas y columnas).

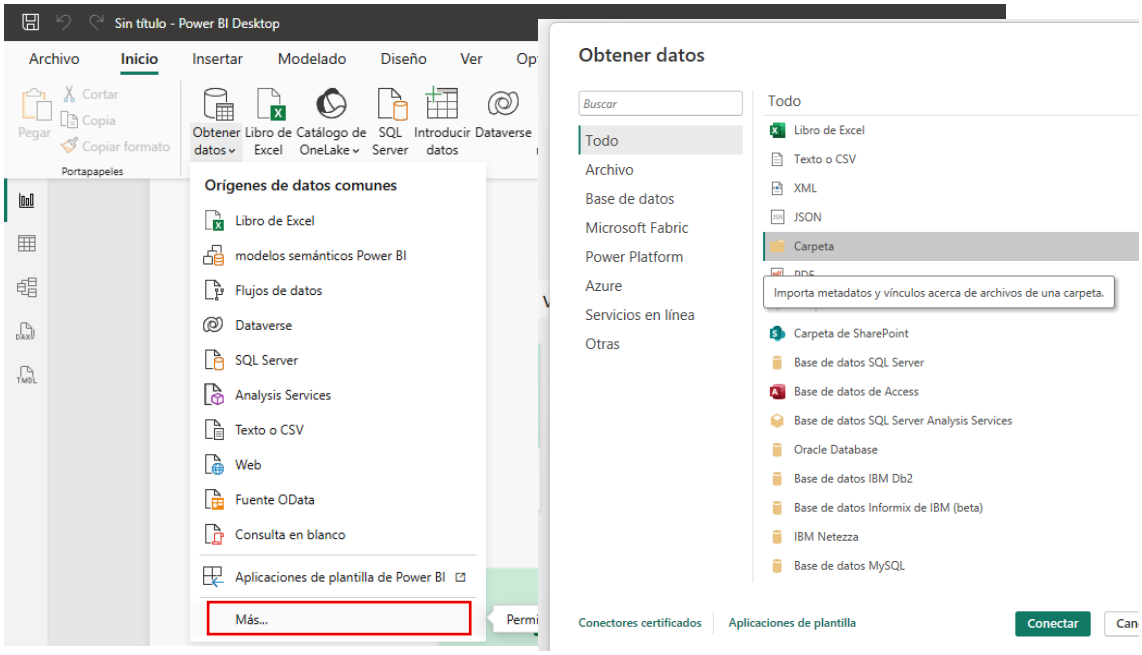
Power BI Desktop organiza el trabajo en tres vistas (iconos en el lateral izquierdo):

- Informe: donde se crean y colocan los gráficos (es la vista principal de trabajo).
- Tabla: donde se ven los datos ya cargados, fila a fila.
- Modelo: donde se ven las tablas y se definen las relaciones entre ellas.



Para poder cargar datos DE PARQUET se hace en dos fases: primero se traen y preparan los datos, y después se cargan al modelo. Estos son los elementos que se usan:

Obtener datos. Punto de entrada para conectar con un origen de datos. Al desplegar Más... aparece el catálogo completo de conectores (ficheros, carpetas, bases de datos, servicios...).



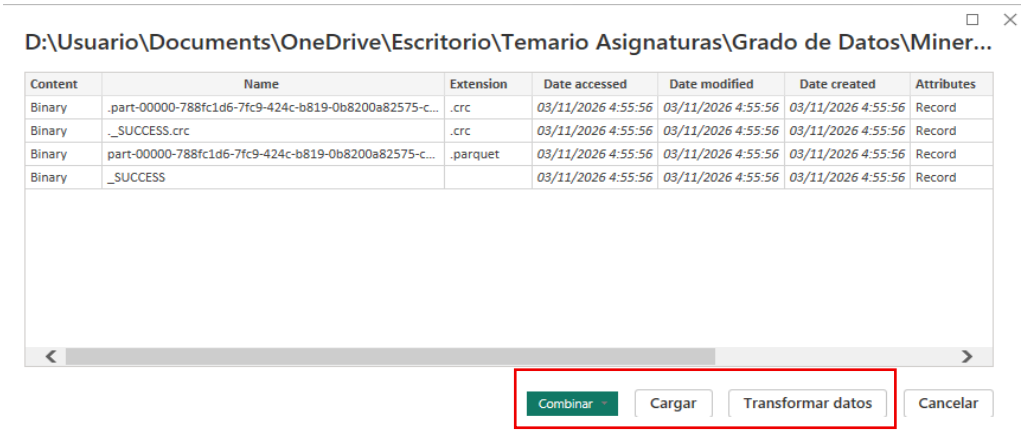
Conector "Carpeta". Lee todos los ficheros de una carpeta y los presenta como una lista (una fila por fichero: nombre, extensión, ruta...), no su contenido todavía. Es el conector adecuado cuando el dato está repartido en varios ficheros, como una carpeta Parquet escrita por Spark. ESTOS PASOS, HASTA LA VISTA DEL MODELO SE REPITEN VARIAS VECES YA QUE SE CARGA DE VARIAS VECES, PRIMERO HECHOS Y LUEGO DIMENSIONES.



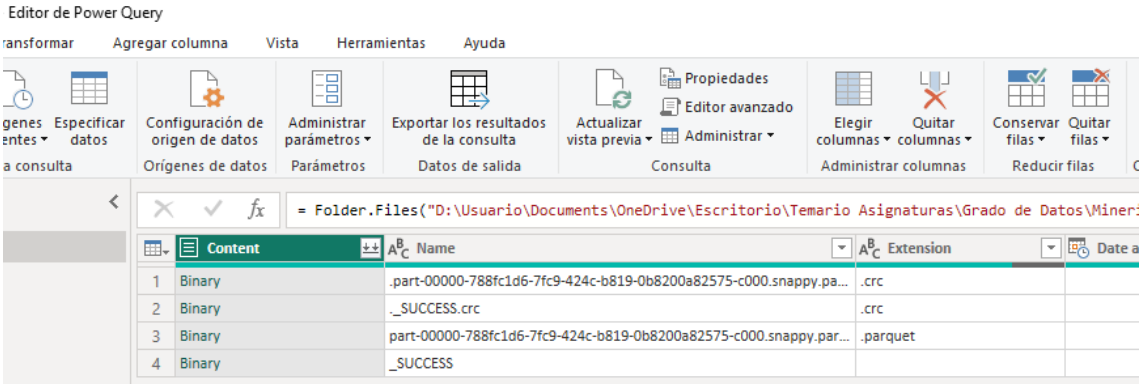
Al conectar, Power BI ofrece tres caminos:

- Cargar: trae los datos directamente, sin tocarlos.
- Transformar datos: abre el Editor de Power Query para limpiar o preparar los datos antes de cargarlos. SE UTILIZARÁ ESTE PARA LOS EJERCICIOS.

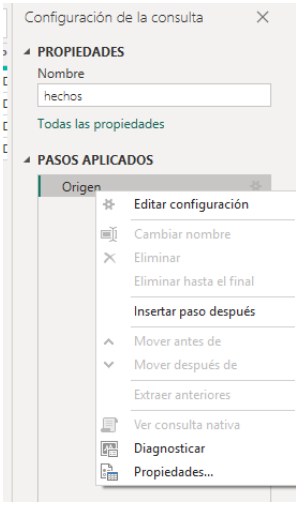
- Combinar y transformar: combina varios ficheros y abre el editor.

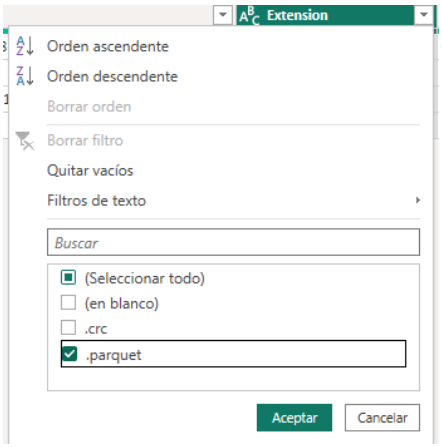


Editor de Power Query es el entorno donde se preparan los datos (filtrar filas, cambiar tipos, combinar ficheros...).



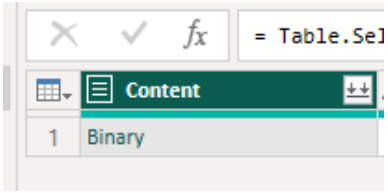
Cada acción queda registrada como un "paso aplicado" (panel derecho) por lo que la preparación es reproducible, y si cambian los datos de origen se vuelven a aplicar los mismos pasos.





Filtro de columna (la flecha ▾ de la cabecera). Filtra las filas según el valor de una columna. Se usa, por ejemplo, sobre la columna Extension para quedarse solo con los .parquet y descartar los ficheros auxiliares que escribe Spark (_SUCCESS y los .crc), que no son datos. ESTE PASO ES NECESARIO PARA LOS DATOS DE PARQUET

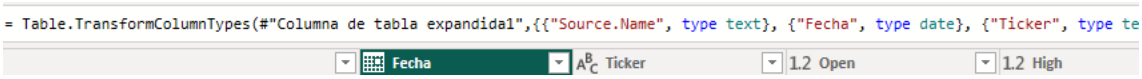
Posteriormente es necesario combinar archivos (icono de dos flechas ⇊ en la columna Content). Toma el contenido de cada fichero de la lista y los apila en una sola tabla, aplicando a cada uno el lector adecuado.



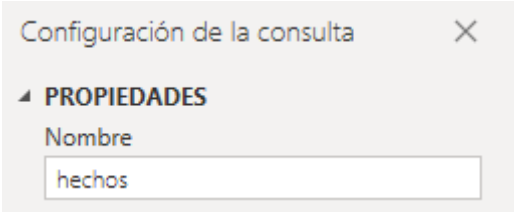
Quitar columnas y tipos. Tras combinar, pueden aparecer columnas, como Source.Name (el nombre del fichero de origen), que no es un dato útil y se pueden quitar. Para ello, botón derecho encima de la columna -> Quitar

	Source.Name	Fecha	Ticker	Open	High
1	part-00000-788fc1d6-7fc9-424c-b819-0b8200a82575-c000.snappy.par...	04/10/2021	ACS.MC	22,98275757	23,18045807
2	part-00000-788fc1d6-7fc9-424c-b819-0b8200a82575-c000.snappy.par...	05/10/2021	ACS.MC	22,93333244	22,93333244
3	part-00000-788fc1d6-7fc9-424c-b819-0b8200a82575-c000.snappy.par...	06/10/2021	ACS.MC	22,35011482	22,36988449
4	part-00000-788fc1d6-7fc9-424c-b819-0b8200a82575-c000.snappy.par...	07/10/2021	ACS.MC	22,31057358	22,6268959

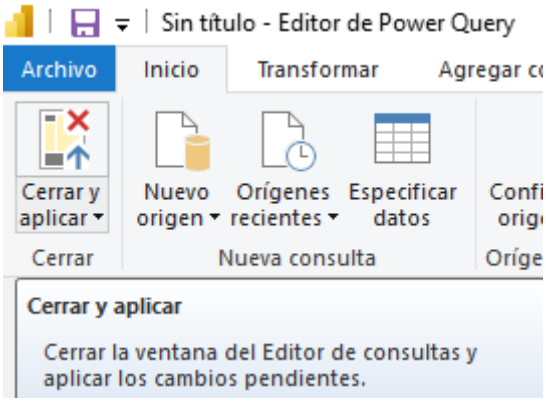
Conviene también revisar los tipos de cada columna (icono ABC/123 de la cabecera). Asegurarse que Fecha está como fecha, Volume como número entero...



Renombrar la consulta. En el panel Consultas se da a la tabla un nombre claro (por ejemplo, hechos o dim_empresa).



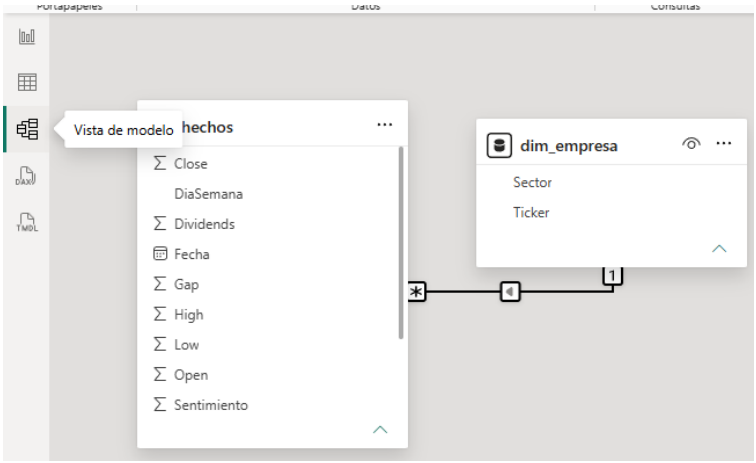
Cerrar y aplicar. Cerrar el editor y aplicar todos los pasos y carga los datos al modelo. A partir de aquí ya se pueden crear gráficos.



Una vez los datos están cargados, se puede observar la relación que presentan los mismos. En la vista Modelo se define el vínculo entre todas las tablas por una clave común (p. ej. Ticker). Una relación tiene:

- Cardinalidad: varios a uno (*:1), uno a varios (1:*), uno a uno... Indica cuántas filas de una tabla se corresponden con cuántas de la otra.

- Dirección del filtro cruzado: por dónde se propaga el filtro (de la dimensión hacia el hecho).



Visual Tarjeta. Muestra un único número destacado (un KPI). Se alimenta de una medida o de un campo con una agregación.

Segmentación de datos (segmentador / slicer). Es un visual que actúa como filtro interactivo para toda la página: al seleccionar un valor (p. ej. un Ticker), el resto de visuales de esa página se filtran por él.

Medida y columna calculada (DAX). Power BI permite crear valores nuevos con DAX (su lenguaje de fórmulas):

- Columna calculada: se evalúa fila a fila y se guarda en la tabla.
- Medida: se evalúa según el contexto del visual (el filtro y la agrupación activos).

Modo Import (y DirectQuery)

Al cargar, Power BI trabaja en modo Import, es decir, copia los datos a su propio modelo en memoria. Las consultas van muy rápidas, pero el dato, si la gold cambia, hay que actualizar para traer la versión nueva.

Existe otro modo, DirectQuery (consulta en vivo contra una base de datos), no aplica a ficheros y se verá en prácticas posteriores, cuando se utilicen datos en MySQL en tiempo real.

TIPOS DE GRÁFICO

Antes de elegir un gráfico, hay que tener en cuenta dos principios:

- **Comprender al usuario. Es esencial saber cómo se usará la visualización y a quién va dirigida**: ¿sirve para decisiones estratégicas o para uso operativo?, ¿es analítica? Quien diseña la visualización asume el papel de narrador de datos, y con él la capacidad de influir en decisiones importantes.
- **Validar los datos. Siempre hay que comprobar los datos que alimentan la visualización —validar su escala y sus elementos fundamentales**—. Ejecutar pruebas automatizadas antes de usarlos crea una red de confianza.

Elegir el gráfico no es una cuestión estética ya que cada tipo responde a una pregunta distinta.

Gráfico de líneas. Permite mostrar cómo evoluciona una magnitud sobre un continuo, sobre todo el tiempo (series temporales). Refleja la tendencia, el ritmo del cambio y los puntos de inflexión y permite destacar cambios sutiles a lo largo de periodos largos.

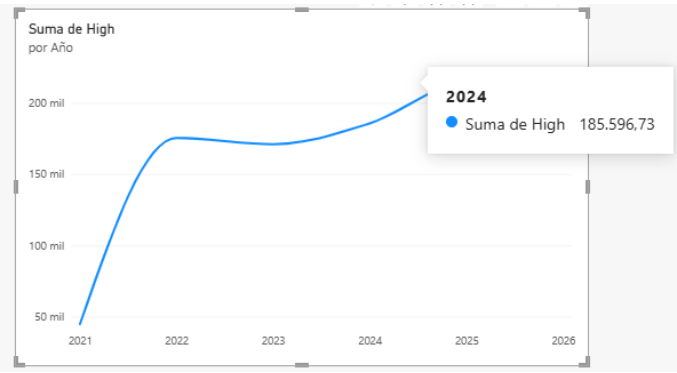
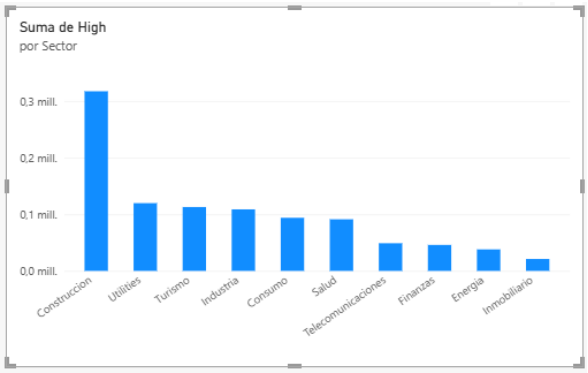


Gráfico de barras / columnas. Permite comparar magnitudes entre categorías (**datos categóricos, no continuos**). Refleja qué categoría es mayor o menor, el orden o ranking y las diferencias entre grupos.



Histograma. Permite ver **cómo se distribuye una variable numérica continua**, agrupando los valores en intervalos. Refleja la forma de la distribución (dónde se concentran los valores, si es simétrica o sesgada, si hay extremos).

Power BI no tiene un visual "histograma" como tal; se hace agrupando en intervalos (bins) y usando un gráfico de columnas. Para una variable:

- Panel Datos → clic derecho sobre la variable → Nuevo grupo.
- En el diálogo, Tipo de grupo → Discretizar.
- Debajo aparece Tipo de discretización con dos opciones:
  - Tamaño del bin → se pone el ancho de cada intervalo (p. ej. 0,5 o 1).
  - Número de discretizaciones → en vez del ancho, se indica cuántas barras se quiere.
- Eje X: arrastra la variable nueva generada.
- Eje Y (Valores): arrastra la varaible original.

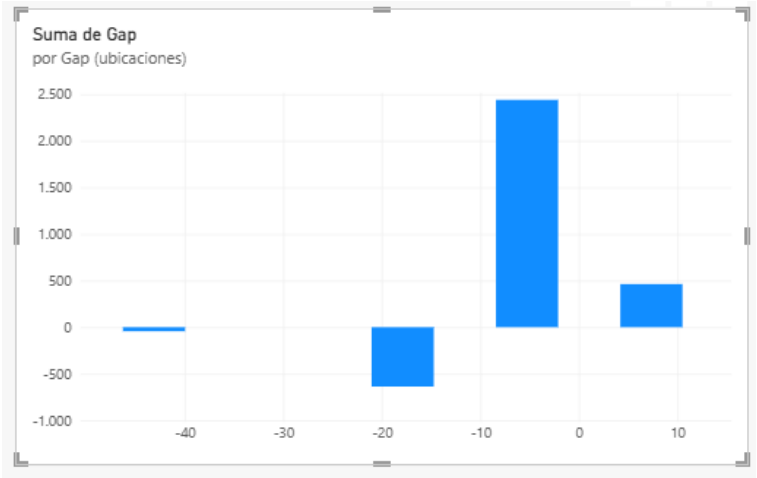


Diagrama de dispersión (scatter). Permite estudiar la relación entre dos variables numéricas. Refleja si existe correlación (y su signo y fuerza), agrupaciones y valores atípicos.

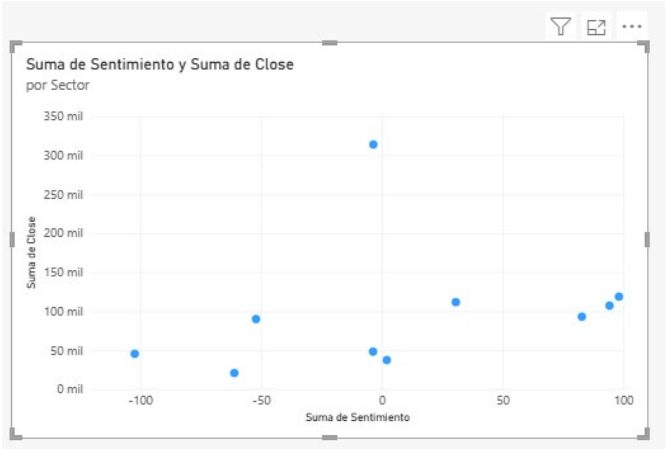


Gráfico circular (tarta). Permite mostrar la composición, qué porcentaje del total representa cada parte. Refleja el peso relativo de cada categoría sobre el 100 %. Cuándo NO usar con muchas categorías o diferencias pequeñas ya quec omparar ángulos es difícil, es mejor usar barras.

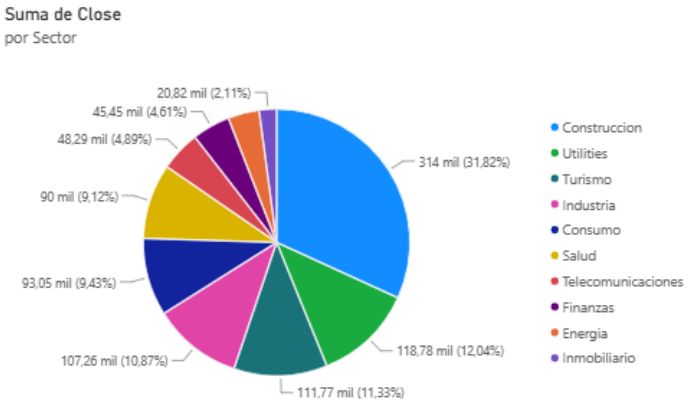
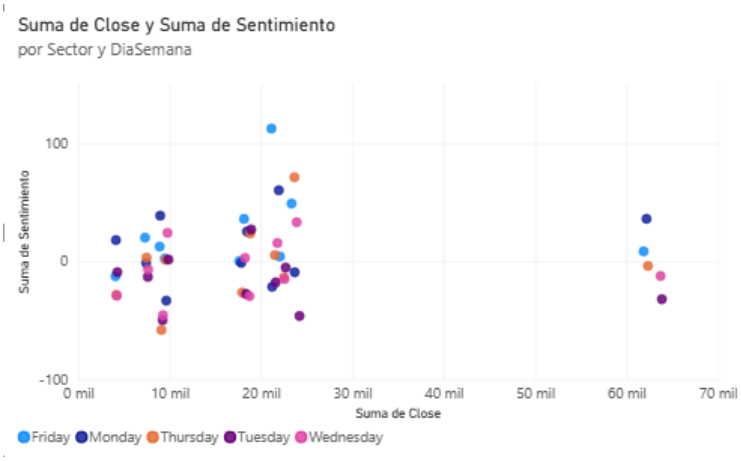
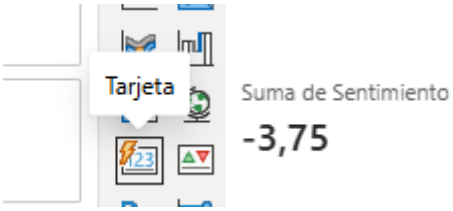


Gráfico de burbujas. Permite saber la dispersión, pero añadiendo una tercera (o cuarta) variable mediante el tamaño (y el color) de cada punto. Refleja la relación entre tres o más magnitudes a la vez. *¿Cuántas variables puedo representar?*



Tarjeta / KPI. Permite destacar un único número clave. Reflejando una métrica resumen de un vistazo (nº de empresas, nº de sesiones, retorno medio, etc).



Qué es un dashboard

Un dashboard es la forma habitual de presentar los datos en la capa de servicio de una plataforma. El rol que los construye es el analista, que crea informes y dashboards. Por tanto, es una colección de gráficos construidos a partir de consultas sobre los datos.

Un dashboard puede actualizarse de forma programada o manual, a la cadencia que se necesite. Muchas herramientas de dashboard permiten alertas con ejecuciones programadas que lanzan un aviso según el resultado de una consulta (por ejemplo, si una métrica cruza un umbral). Son útiles para vigilancia.

Para diseñar bien un dashboard es necesario diseñar con criterio. Conviene entender al usuario y el propósito del panel (no es lo mismo uno para decisiones críticas que uno operativo), planificar qué datos necesita antes de construirlo, validar los datos que lo alimentan y elegir la herramienta que mejor encaje a las necesidades y a las capacidades de la organización.

El segmentador

Un segmentador (slicer, "Segmentación de datos") es un visual que funciona como filtro interactivo para toda la página: al seleccionar un valor, todos los demás visuales de esa página se filtran por él. Es lo que permite, por ejemplo, cambiar el dashboard por empresa con un clic.

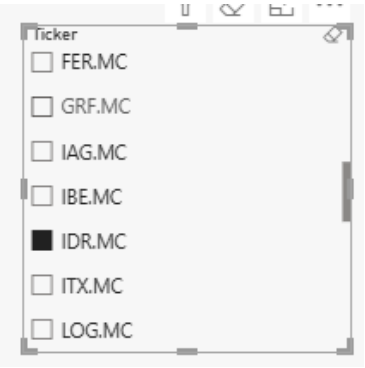
Crearlo:

1. Una vez esta el dashboard, Haz clic en una zona vacía del lienzo.
2. En Visualizaciones, elige Segmentación de datos (pasa el ratón por los iconos para ver el tooltip).



3. Con el segmentador seleccionado, en Datos marca dim_empresa[Ticker] (o arrástralo al visual). Aparece la lista de tickers.

4. Clic en un ticker (p. ej. BBVA.MC) → toda la página (la línea de precio, las tarjetas, etc.) se filtra a esa empresa.



5. Para quitar el filtro: hay que volver a clicar el valor, o usa el icono de goma de borrar que aparece arriba del segmentador.

Opciones útiles:

- Desplegable (ocupa menos espacio): con el segmentador seleccionado, la flecha ▾ de su esquina → Desplegable (en vez de Lista).
- Selección única (una empresa a la vez): Formato → Configuración de la selección → Selección única.

Importante: el segmentador y los visuales que quieres filtrar deben estar en la misma página ya que al clicar un valor, los visuales se actualizan solos.

EJERCICIOS

Como en las prácticas anteriores, se entrega el proyecto completo además de el archivo .pbix de Power BI y un informe en PDF que, por cada ejercicio donde se requiera, incluya la justificación del tipo de gráfico elegido, los datos/medidas usados y un análisis de lo observado.

- Ej1: Conectar e importar. Conecta Power BI a la gold en Parquet (conector Carpeta, una vez por tabla: hechos y dim). Combina los ficheros, revisa tipos y renombra las consultas.

- Ej2: Modelo en estrella. En la vista Modelo, crea/verifica la relación hechos y dim. Explica en el informe por qué es un modelo en estrella y qué permite. Añade una imagen con tu modelo en estrella.

- Ej3: Panorama. Crea tarjetas al menos dos tarjetas o KPI.

- Ej4: Evolución del precio (línea). Gráfico de línea del Close (como Promedio) por Fecha, con un segmentador por Ticker para elegir una empresa. Comenta la tendencia.

- Ej5 (opcional): Efecto viernes. Gráfico de barras del retorno medio por día de la semana (DiaSemana). Comprueba si los viernes se comportan distinto al resto y coméntalo (contexto: finanzas conductuales).

- Ej6 (opcional): Otro análisis. A tu elección con los datos adicionales de la práctica anterior muestra, seleccionando el grafico adecuado, la gráfica.

- Ej7: Diseña el dashboard. Haz un estudio sobre todas las variables y sus relaciones que te gustaría mostrar y como (es decir, selecciona el grafico adecuado y justifica cada uno en el informe). Tienes que mostrar el mayor número de relaciones que puedas entre variables, pero siguiendo un orden, no con gráficos mezclados. Puedes usar la IA para ayudarte o investigaciones. Argumenta en el informe porqué has elegido esa distribución.

- Ej8 (opcional): Investiga la pestaña Vista → Temas. Eliges uno de los que trae o “Personalizar el tema actual” para fijar tu paleta, tipografía y fondos. Puedes usar la IA para ayudarte.



- Ej9: Incluye en el informe una captura del dashboard para cada uno de los sectores y comenta las relaciones que has encontrado. (internas, dentro del sector y externas, entre sectores)

ENTREGA

Se mantienen las normas de entrega de las prácticas anteriores. Tened en cuenta donde guardáis el archivo de Power BI.